

AICAS 2026 Grand Challenge Hardware

目录

- [概述](#)
- [软件环境](#)
- [代码介绍](#)
- [测试流程](#)
- [提交指南](#)
- [评分标准](#)

概述

本赛道需要在KV260平台的硬件条件下部署和运行大模型，利用片上的CPU以及FPGA资源，开展多模态视觉语言模型（VLM）的端侧推理芯片架构设计优化。

软件环境

服务器网址

<http://212.129.248.110:8996/signin/>

请参赛选手自行注册账号

板卡申请

如图

FPGA Remote Access

With FPGA remote access service, you can create your all-programmable design easily without a physical board. The FPGA access token will be used for identification.

FPGA Access Token:

fc2c72afdaf767fbe5773f029f2d4741af5e586cead85913da451d7d0cc81f3a

Select your desired board:

- ☐ PYNQ-Z2
☒ KV260

[Apply for a FPGA board](#)

其中Token为：fc2c72afdaf767fbe5773f029f2d4741af5e586cead85913da451d7d0cc81f3a

Board Loaded

Please wait for ~30 seconds and then click the following link to access your board. The board needs some time to configure and load files.

Link: 212.129.248.110:8503

Expiration: 2026-01-22 17:58:20

Password: h&fvxy\$|^rj)o%twm#e@

If you want to realase the board in advance, please click [here](#).

申请成功后，点击图中给出的链接，输入密码，即可进入JupyterNotebook界面。

共享文件夹地址

进入JupyterNotebook后打开终端，共享文件夹位置为 `/root/sjtu-bin/AICAS`

- `venv` 提供了一个基于 `pyvenv` 的虚拟环境
- `data` 为存放数据集的文件夹
- `gguf` 为存放模型权重的文件夹
- `bin` 为存放llama.cpp的文件夹

代码介绍

sample.py

提供了采样代码，对**57817**个原始测试数据进行采样，得到随机的100个测试数据。

在初赛阶段，其采样的测试类型为：

测试名称	采样个数
Regular Text Recognition	10
Irregular Text Recognition	10
Artistic Text Recognition	10
Handwriting Recognition	10
Digit String Recognition	10
Non-Semantic Text Recognition	10
Scene Text-centric VQA	40

请注意，复赛的测试**抽样类型可能不同**。

acc_eval.py

对采样得到的数据集进行推理，并得到准确率和原始回答结果。

throughput_eval.py

使用较长的prompt和较大的图片进行推理，测试得到模型两个阶段的吞吐量。

测试流程

本测试流程旨在在kv260平台上仅利用cpu对 `smo1v1m2-500M` 进行部署，参赛选手可以参考此运行方法，或者采用自己编写的脚本部署该模型，**选手最后提交的部署方案必须使用kv260平台的FPGA资源。**

环境准备

我们为demo运行提供了python测试虚拟环境。

```
source venv/bin/activate
```

数据集采样

```
python sample.py -i <FULL_TEST_JSON_PATH> -o <SAMPLED_JSON_PATH>
```

准确率测试

所需要的权重已经在共享文件夹中。

进入共享文档中的 bin 文件夹

在shell中启动llama-server

```
./llama-server -m <GGUF_PATH>/Smo1VLM2-500M-Video-Instruct-f16.gguf --mmpoj  
<GGUF_PATH>/mmpoj-Smo1VLM2-500M-Video-Instruct-f16.gguf
```

打开另一个shell，运行准确率测试

```
python acc_eval.py --image_folder <IMAGE_FOLDER_PATH> --OCRBench_file <SAMPLED_JSON_PATH> --  
output_folder <OUTPUT_FOLDER> --save_name Smo1VLM2
```

其中<IMAGE_FOLDER_PATH>为共享文件夹中的data文件夹。

吞吐量测试

吞吐量测试所需输入的图片包含在压缩包中

不要关闭llama-server，直接运行吞吐量测试

```
python throughput_eval.py -i <THROUGHPUT_IMAGE_PATH> -o <OUTPUT_JSON_PATH>
```

其中<THROUGHPUT_IMAGE_PATH>为共享文件夹中的image.png文件。

之后请统一命名文件为天池平台规定的格式并上传。

提交指南

必需文件

初赛阶段要求提交以下文件：

1. 吞吐量测试生成的json文件；
2. 测试报告：介绍本队伍对Smo1VLM2-500M-Video-Instruct进行优化后的测试结果，并提供指定第三方测试软件运行结果文档；
3. 技术文档：介绍本队伍对大模型实现优化方法，我们将提供一个markdown模板作为参考；

4. 实现优化方法的源代码。

在最后一轮比赛结束后，参赛队伍需要提交：

1. 参赛论文: 以论文形式介绍本队伍VLM应用场景，软硬件协同设计方案，以及优化前后各评价指标的对比效果和性能总结。
2. 源代码: 必须提交用于优化模型的实际源代码。(竞赛组织方有权利在开源社区（例如Github, Huggingface等）中使用GC参赛团队的代码和开发案例作为宣传材料，或者用于其在赞助商相关产品的开源工具中)

提交方法

1. 吞吐量测试生成的json文件：在赛事首页——提交结果页面以json格式提交；
2. 其余文件：保存至百度网盘，然后将网盘链接以邮件的形式发送至组委会邮箱。

评分标准

测试评分标准

评价指标	评价内容	使用方法
模型推理精度（Ability）	精度能力测试	本地运行分析工具，生成json文件
模型推理性能（Efficiency）	吞吐量提升率	本地运行分析工具，生成json文件

A. 初赛评价指标

1. 模型推理精度评估

准确率测试：在该赛道中，使用测试集 OCRBench 进行 n 个测试样例的精度测试。每个 OCRBench 的测试样例提供一张图片、一个问题和一个答案，模型需要根据输入的图片和问题输出正确答案。设正确答案字符串为 $\{p_i\}, i \in [1, n]$ ，选手在 KV260 平台上部署的 SmolVLM2-500M-Video-Instruct 在给定输入下的输出为 $\{q_i\}, i \in [1, n]$ 。程序中以 $p_i \subseteq q_i$ 作为正确指标，准确率计算公式如下：

$$\text{Ratio}_{\text{accuracy}} = \frac{\sum_{i=1}^n \mathbb{1}_{p_i \subseteq q_i}}{n}$$

在初赛中，n 的值设定为 100。

2. 模型推理性能评估

prefill 和 decoding 吞吐量提升率：以初始 SmolVLM2-500M-Video-Instruct 在硬件平台的吞吐量作为 T_{ori} ，以优化后的 SmolVLM2-500M-Video-Instruct 吞吐量作为 T_{opt} ，prefill 和 decoding 两阶段结果分别计算。具体计算公式如下：

Prefill阶段：

$$\text{Ratio}_{\text{throughput_P}} = \frac{T_{\text{opt_P}} - T_{\text{ori_P}}}{T_{\text{opt_P}}} = 1 - \frac{T_{\text{ori_P}}}{T_{\text{opt_P}}}$$

Decoding阶段：

$$\text{Ratio}_{\text{throughput_D}} = \frac{T_{\text{opt_D}} - T_{\text{ori_D}}}{T_{\text{opt_D}}} = 1 - \frac{T_{\text{ori_D}}}{T_{\text{opt_D}}}$$

我们鼓励参赛选手进行硬件层面的优化，以达到更高的模型吞吐量为目标。

3. 初赛总分计算方法

在比赛开始前，主办方通过完全随机的方式从OCRBench的所有数据集中选择100个数据，并将其保存为json格式，选手在比赛结束前无法获取到该json文件的内容，主办方将提供完全随机的采样代码提供给每个队伍进行测试，同时公布在没有任何优化的情况下的准确率数据。

在比赛结束后，主办方将公布准备好的json测试文件，并对选手提交的优化后的FPGA加速工程进行准确率评估，我们会对所有的队伍使用相同的测试文件。并与原始权重状态下的准确率进行比较，分别记为 Acc_{ori} ， Acc_{opt} ，对于精度测试，其测试通过以下公式进行：

$$Acc_{opt} \geq Acc_{ori} - 5\%$$

在通过精度测试后，将进行模型推理性能评估，得到初赛的总分。

初赛的总分将被加权计算，各项指标在加权公式中会以全部参赛团队中每项的最高分进行归一化。选手们将自己的结果上传至天池平台，平台会线上给出总分结果和排名。具体计算公式如下：

最终评分公式：

$$Score = 50 \times \frac{Ratio_{throughput_P}}{MAX(Ratio_{throughput_P})} + 50 \times \frac{Ratio_{throughput_D}}{MAX(Ratio_{throughput_D})}$$

由于天池排行榜的测评限制，在线排行榜显示的分数为：

$$Score = 50 \times Ratio_{throughput_P} + 50 \times Ratio_{throughput_D}$$

B.复赛评价指标

复赛的评价标准将基于初赛的结果进行适当的调整。